# 預測學習｜作業一實驗報告

KNN 分類、模型複雜度選擇與五折交叉驗證

## 摘要

本報告整理第 2.7、2.8、2.11 與 2.12 題。前兩題以州肥胖率作為唯一特徵，使用 KNN 預測總統大選的 D / R 標籤；後兩題對同一組十筆含雜訊資料擬合代數與餘弦模型，並比較模型選擇與驗證結果。

| 題目 | 主要方法 | 主要結果 |
| --- | --- | --- |
| 2.7 | 2004 訓練 → 2000 測試；LOOCV 選 k | k = 7；測試錯 26/51，準確率 49.02% |
| 2.8 | 2000 訓練 → 2004 測試；LOOCV 重新選 k | k = 7；測試錯 22/51，準確率 56.86% |
| 2.11 | Schwartz 準則選模型階數 m | 代數 m = 1；餘弦 m = 0 |
| 2.12 | 五折交叉驗證評估兩模型族 | 餘弦平均 MSE 0.20392；代數 188.69045 |

## 資料與實驗範圍

選舉資料各有 51 筆州 / 華盛頓特區觀測值。2000 年 D=21、R=30，平均肥胖率 19.10%；2004 年 D=19、R=32，平均肥胖率 22.39%。肥胖率為輸入 x，選舉結果為分類標籤 y；並未預測肥胖率。

迴歸資料另由固定亂數種子 42 生成：x 在 [0,1] 均勻抽取 10 筆，$y = x^2 + 0.1x + \varepsilon$，ε 為標準差 0.5 的常態雜訊。兩種模型使用相同的十筆資料。

### 閱讀重點

交叉驗證用來選擇 k 或評估模型；測試年份不參與 KNN 的 k 選擇。Schwartz 分數用於平衡訓練誤差與模型複雜度，並非獨立測試誤差。第 2.12 題則以訓練折之外的觀測值檢查預測表現。

資料與重現依據：HW1/data/、HW1/src/、HW1/results/tables/ 與 HW1/results/figures/。本報告數值採目前程式固定的 brute KNN 後端；資料原始標籤照提供的 CSV 保留。

# 2.7 | 以 2004 年資料預測 2000 年

目標是利用 2004 年各州肥胖率及 D / R 結果建立分類器，再輸入 2000 年各州的肥胖率，預測其 2000 年選舉標籤。這是跨年份回推的測試。

## 方法

只有一個特徵，因此歐氏距離為 $|x - x_i|$。選取最近的 k 個訓練州，以等權多數決預測 D 或 R。對 k=1,...,50 逐一做留一交叉驗證（LOOCV）：每次以 50 筆擬合、1 筆驗證，計算 51 次的錯誤率；最低錯誤率並列時取最小 k。最後用全部 2004 年資料重新擬合，再測試 2000 年。

| 最低 LOOCV 錯誤 | 並列最佳 k | 選用 k | 2000 測試 |
|---|---|---|---|
| 14/51 = 27.45% | 7、20、22 | 7 | 錯 26/51；準確率 49.02% |

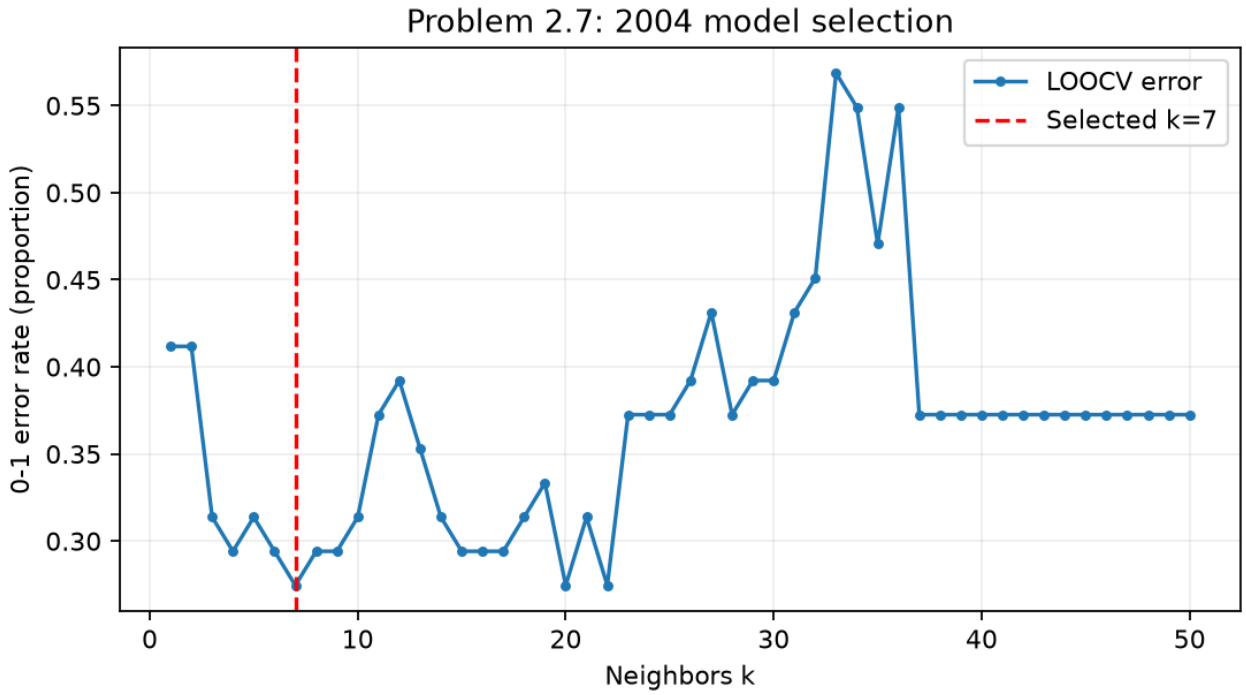



圖 1 2004 年訓練資料的 LOOCV 錯誤率；紅線標示依並列規則選出的 k=7。

## 結果解讀

測試集混淆矩陣：實際 D 中 17 筆判為 D、4 筆判為 R；實際 R 中 22 筆判為 D、8 筆判為 R。最低驗證錯誤的 k 不保證跨年份預測良好；本題測試錯誤率 50.98%，高於 2004 年內部 LOOCV 的 27.45%。

k=7、20、22 在此驗證指標上同分。採用 k=7 是事先明確指定的並列選擇規則，不代表較小 k 在所有資料上必然較好。

# 2.8 | 以 2000 年資料預測 2004 年

此題與 2.7 使用相同的 KNN 方法，但訓練及測試年份對調：以 2000 年資料選擇並擬合模型，再用 2004 年各州肥胖率預測其 D / R 標籤。k 必須在 2000 年訓練資料上重新選取。

| 最低 LOOCV 錯誤 | 並列最佳 k | 選用 k | 2004 測試 |
|---|---|---|---|
| 19/51 = 37.25% | 7、9、16、24–28 | 7 | 錯 22/51；準確率 56.86% |

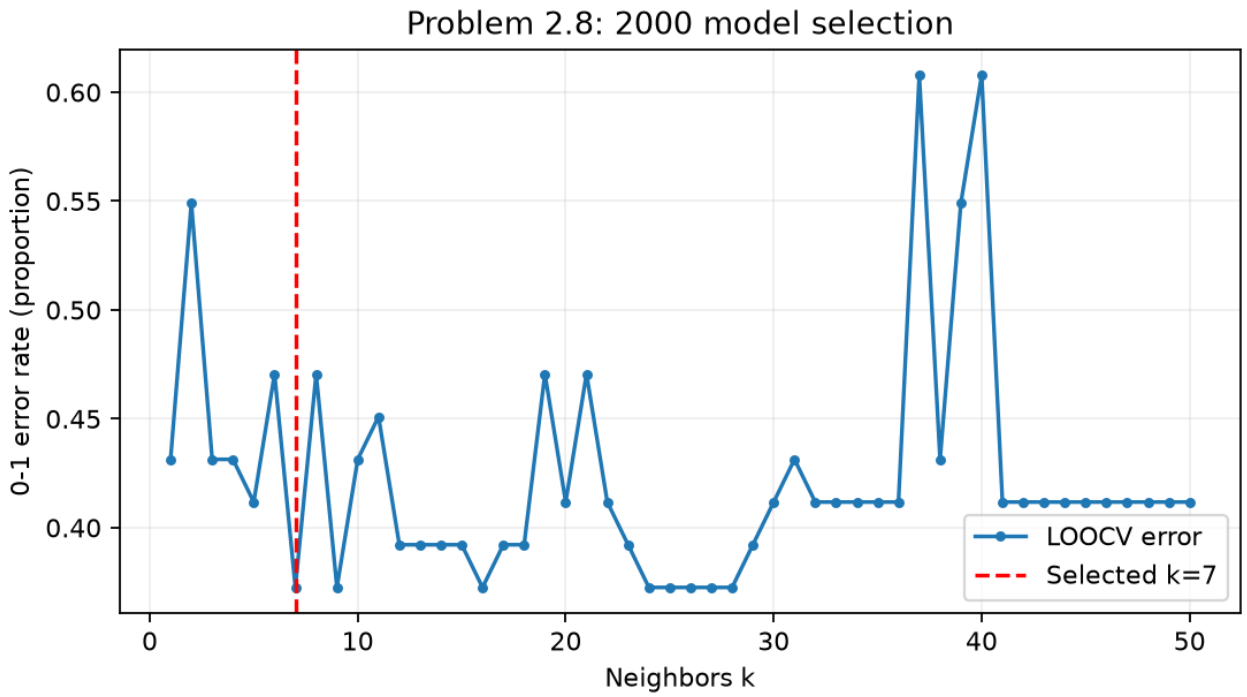



圖 2 2000 年訓練資料的 LOOCV 錯誤率；此題獨立選出的 k 也等於 7。

## 跨年份結果比較

| 題目 | 訓練 → 測試 | LOOCV | 測試錯誤率 | 測試正確率 |
|---|---|---|---|---|
| 2.7 | 2004 → 2000 | 27.45% | 50.98% | 49.02% |
| 2.8 | 2000 → 2004 | 37.25% | 43.14% | 56.86% |

2.8 測試集的混淆矩陣為：實際 D 中 2 筆判為 D、17 筆判為 R；實際 R 中 5 筆判為 D、27 筆判為 R。雖然總正確率略高於 2.7，對 D 類的辨識仍偏弱。兩個年份的肥胖率分布與標籤比例不同，而且測試的是同一批州的另一年份，不能把差異解讀成肥胖率造成投票結果。

重現說明：目前程式明確採用 algorithm='brute'、歐氏距離及等權投票。當不同州與待測值等距時，鄰居的邊界處理可能影響預測；本報告不混用 auto 後端的另一次試算結果。

## 2.11 | 兩種模型族與 Schwartz 準則

同一組十筆含雜訊資料分別交給兩種模型。代數模型使用 1、x、$x^2$、…、$x^m$；餘弦模型使用 1、cos(2πx)、cos(4πx)、…、cos(2πmx)。$w_0$ 至 $w_m$ 由最小平方法估計。m 越大，模型可調整的係數越多。

| 模型族 | m=0 | m=1 | m=2 |
|---|---|---|---|
| 代數 | $w_0$（常數） | $w_0+w_1x$（直線） | $w_0+w_1x+w_2x^2$（二次） |
| 餘弦 | $w_0$（常數） | $w_0+w_1\cos(2\pi x)$ | 再加 $w_2\cos(4\pi x)$ |

每個 m 都有 DoF=m+1 個待估係數。令 n=10、p=DoF/n，R_emp 是十筆訓練資料的平均平方誤差（MSE）；本題採用 R_SC = [1 + p ln(n)/(1-p)] × R_emp。對兩模型族分別試 m=0,…,8，選 R_SC 最小者。係數增加時，訓練 MSE 往往下降，但 Schwartz 倍率上升。

| 模型族 | 選用 m | DoF | 訓練 MSE | 最小 Schwartz 分數 |
|---|---|---|---|---|
| 代數 | 1 | 2 | 0.08084 | 0.12738 |
| 餘弦 | 0 | 1 | 0.10764 | 0.13518 |

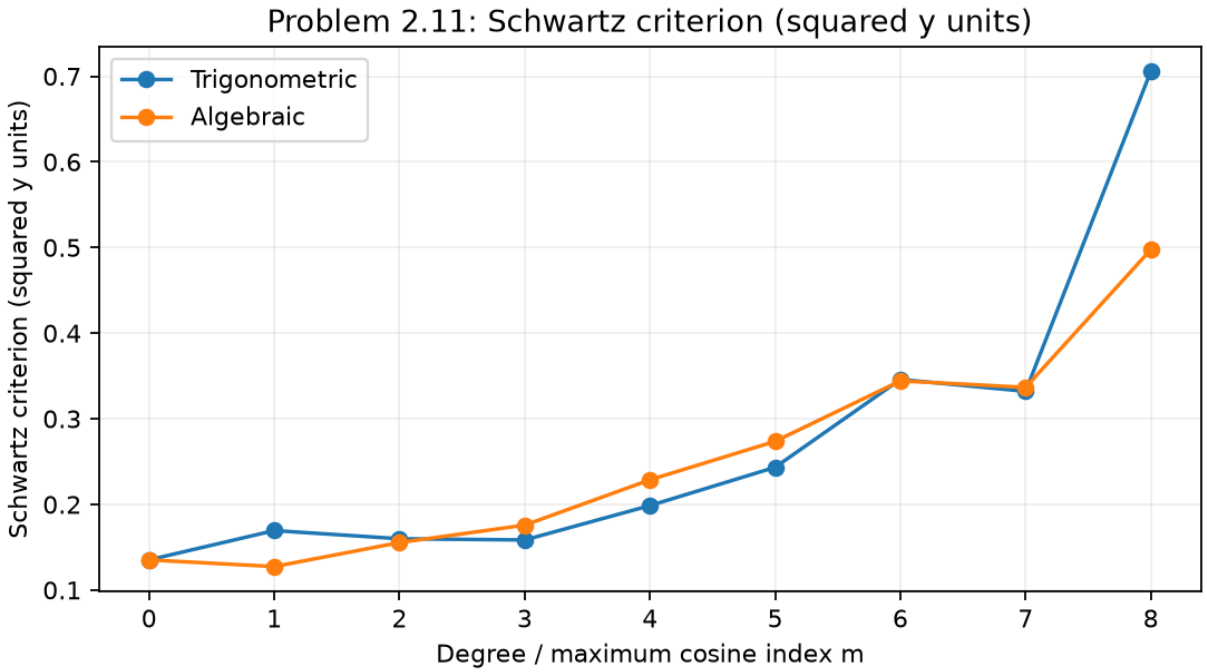



圖 3 m 增加時兩模型族的 Schwartz 分數。每個模型族各選曲線最低點。

代數 m=2 的訓練 MSE 0.07822，比 m=1 的 0.08084 稍低；但 Schwartz 分數升至 0.15541，因此選 m=1。生成函數雖是二次式，小樣本含雜訊下的選擇準則並不保證找回 m=2。餘弦模型在此資料選 m=0；其有限個餘弦項也無法精確表達原始函數 $x^2+0.1x$。

## 2.12 | 五折交叉驗證與結論

把相同十筆資料分成五折，每折以 8 筆訓練、2 筆驗證。在每個訓練折內，代數與餘弦模型各自重新以 Schwartz 準則選 m；再預測該折未參與擬合的兩筆資料。平均五折驗證 MSE 用來比較兩模型族的預測表現。

| 驗證折 | 餘弦 m | 餘弦 MSE | 代數 m | 代數 MSE |
|---|---|---|---|---|
| 1 | 0 | 0.01793 | 1 | 0.02860 |
| 2 | 0 | 0.14729 | 6 | 942.63846 |
| 3 | 5 | 0.40218 | 3 | 0.33297 |
| 4 | 0 | 0.24554 | 0 | 0.24554 |
| 5 | 0 | 0.20666 | 0 | 0.20666 |

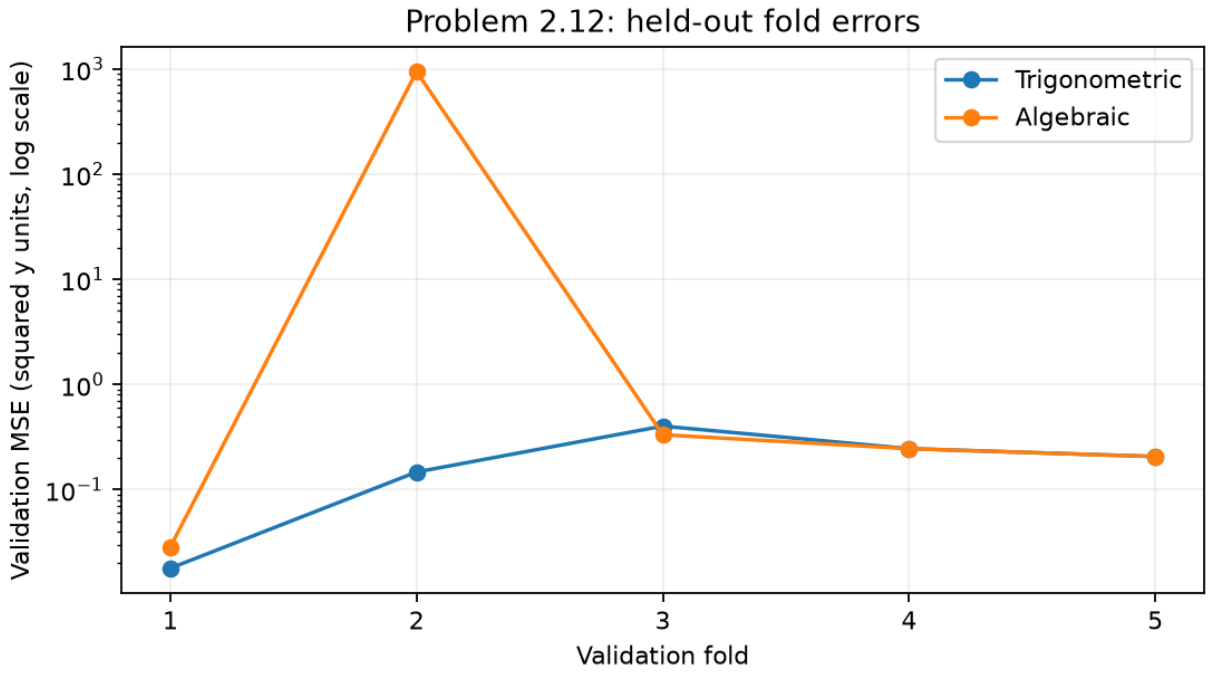



圖 4 各折驗證 MSE；縱軸為對數刻度，使第 2 折的極大誤差與其他折可同圖顯示。

| 模型族 | 平均五折驗證 MSE | 折間標準差 |
|---|---|---|
| 餘弦 | 0.20392 | 0.14040 |
| 代數 | 188.69045 | 421.46977 |

本次實驗中，餘弦模型的平均驗證誤差較小。代數模型第 2 折在 8 筆訓練資料上選 m=6，對兩筆未見資料產生 942.64 的 MSE，主導整體平均值。這呈現高階多項式在極小樣本下可能不穩定；不能僅以 2.11 的訓練資料 Schwartz 最低分數宣稱代數模型預測一定較好。

結論：KNN 在跨年份的選舉預測僅有約半數正確，肥胖率單一特徵不足以可靠判斷標籤；在迴歸實驗中，模型選擇準則與獨立折驗證回答不同問題，應分別報告。